

Modelo de Efectos Fijos en R

22 de agosto de 2023

INSTITUTO TECNOLÓGICO AUTÓNOMO DE MÉXICO (ITAM)

Seminario de Investigación Económica

Instructor: Horacio Larreguy

Asistente: Eduardo Zago

1. Datos Panel

Empezamos este tutorial recordando la estructura de las bases de datos panel. Recordemos que los datos panel combinan las dimensiones de corte transversal y serie de tiempo, y se pueden definir de la siguiente manera:

$$\{x_{it} : i = 1, 2, \dots, n, \quad t = 1, 2, \dots, T\}$$

Tabla 1: Datos Panel Balanceados

unidades	tiempo	Y	X
i_1	t_1	1.3	.0064436723
i_1	t_2	1.2	.51859677
i_1	t_3	3	.3410252
i_2	t_1	1.25	.88488311
i_2	t_2	1.32	2.954581
i_2	t_3	4	4.2451215
...			
i_n	t_1	0.94	3.49329
i_n	t_2	1.1	3.8499
i_n	t_3	4	2.629

En palabras, en los datos panel las unidades pueden ser observadas repetidamente a través de distintos periodos en el tiempo. Estas unidades pueden ser individuos, estados, países y para la mayoría de sus proyectos serán municipios. Es importante resaltar, ya que en algunos de sus proyectos se da el caso, que la variable t no representa el tiempo en sí. Otros ejemplos de cómo puede estar estructurada son: i podría representar municipios y t ciudades; i podría representar partidos políticos y t candidatos.

2. Efectos Fijos: Intuición

Antes de empezar con la intuición del modelo de efectos fijos, es muy importante recalcar que la motivación de este modelo es eliminar el sesgo que puede causar una variable que sea constante dentro de un mismo grupo, ya sea observada o no-observada. Cuando decimos que una variable es no-observada, nos referimos a que no esta en nuestra base de datos y probablemente sea una variable muy difícil de medir/cuantificar (por ejemplo: la habilidad).

Supongamos que estamos en el contexto de una base de datos en formato panel con N individuos y 2 periodos de tiempo. Nos interesa entender como afectan los niveles educativos de cada individuo a su ingreso. Sabemos que el ingreso de un individuo es afectado por muchos factores, uno de ellos siendo la habilidad. Supongamos que la habilidad de los individuos es constante en el tiempo e igual a A_i . Entonces tenemos la siguiente especificación:

$$Ing_{it} = \alpha + \tau Educ_{it} + \beta X'_{it} + \gamma A_i + \epsilon_{it} \quad (1)$$

Donde X_{it} representa una matriz que tiene por columnas controles observables que difieren entre individuos y además varían en el tiempo (noten la diferencia en los subíndices). Recordemos que la habilidad no es una variable observable, por lo que no podríamos estimar el coeficiente τ sin sesgo por variables omitidas. Una forma de lidiar con el sesgo provocado por variables omitidas constantes en el tiempo es utilizando el modelo de primeras diferencias¹. Observemos que en realidad tenemos dos ecuaciones, para $t = 1$:

$$Ing_{i1} = \alpha + \tau Educ_{i1} + \beta X'_{i1} + \gamma A_i + \epsilon_{i1} \quad (2)$$

y para $t = 2$:

$$Ing_{i2} = \alpha + \tau Educ_{i2} + \beta X'_{i2} + \gamma A_i + \epsilon_{i2} \quad (3)$$

¹Este modelo se desarrolla con mayor profundidad en las Notas de Arturo Aguilar

Si restamos la ecuación (2) y la (1) obtendríamos:

$$\Delta_1 Ing_i = \tau \Delta_1 Educ_i + \beta \Delta_1 X'_i + \Delta_1 \epsilon_i \quad (4)$$

Y de esta forma podríamos estimar el coeficiente *tau*. Sin embargo, este modelo tiene sus limitaciones. Una de ellas es que no se puede estimar los coeficientes de variables observables que sean constantes en el tiempo, ni α . Además, se necesita realizar un calculo más, la diferencia, que de tener más periodos se podría complicar bastante. Por lo tanto, lo que se usa para resolver el sesgo por variables constantes entre grupos omitidas son los efectos fijos. Como correctamente dice Arturo en sus notas, si modificamos el modelo agregando dummies para cada individuo o grupo, el efecto de la variable no observada A_i será absorbido por estas variables dado que será **colinear** con dichas variables. ¿A qué nos referimos con colinear?

Recordemos que un vector y es una combinación lineal de $x_1, \dots, x_k \in \mathbb{R}$ si:

$$\exists \quad \alpha_1, \dots, \alpha_k \in \mathbb{R} \quad s.t. \quad y = \alpha_1 x_1 + \dots + \alpha_k x_k$$

Es decir, y es combinación lineal de los vectores x_i si existen escalares α tales que puedo llegar a y multiplicando los escalares por los vectores y sumándolos. Para entender la relevancia en nuestro caso supongamos que si podemos cuantificar la variable A_i del 1 al 100 con un test de aptitudes, y para simplificar el análisis supongamos que $N = 3$, entonces, tendríamos la siguiente base de datos:

Tabla 2: Base de datos:

Individuos	tiempo	Ing	Educ	A	Dummy i_1	Dummy i_2	Dummy i_3
i_1	t_1	1.3	.0064436723	80	1	0	0
i_1	t_2	1.2	.51859677	80	1	0	0
i_2	t_1	1.25	.88488311	93	0	1	0
i_2	t_2	1.32	2.954581	93	0	1	0
i_3	t_1	0.94	3.49329	72	0	0	1
i_3	t_2	1.1	3.8499	72	0	0	1

Notamos que A varía entre individuos pero no entre periodos de tiempo y que tenemos tres vectores:

$$x_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}, x_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, x_3 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 1 \\ 1 \\ 1 \end{bmatrix}$$

De aquí es fácil ver que si elegimos $\alpha_1 = 80$, $\alpha_2 = 93$ y $\alpha_3 = 72$ tenemos que:

$$A = \alpha_1 x_1 + \alpha_2 x_2 + \alpha_3 x_3$$

Por lo tanto el vector A es una combinación lineal de los vectores x_i , es decir, de las dummies por individuo. Más aún, cualquier variable constante en el tiempo (raza, sexo, etc...) es de igual forma colineal a los efectos fijos y, como mencionamos, agregarlas en una regresión absorbe el efecto (variación) de estas variables. Por lo tanto, agregar efectos fijos te permite controlar por todas estas variables observables (que de igual forma hay que conseguir) y, además, con todas las variables no observables que sean

constantes entre grupos².

Por último, Es importante recordar la interpretación de las variables dummy: te dicen la diferencia de una media ponderada de los individuos que pertenecen al grupo identificado con la variable dummy respecto al grupo de referencia (i.e. la variable dummy omitida). Se omite una variable ya que de no hacerlo, se tendría multicolinealidad perfecta, lo cual es una violación al supuesto 6 de OLS.

3. Efectos Fijos: Aplicación en R

Como vimos en clase, una forma fácil de agregar los efectos fijos en R es usando la función `felm` del paquete `lfe`. Recordemos el ejemplo que vimos para el DiD, donde estimamos dos modelos:

Two Way Fixed Effects, el cual esta especificado de la siguiente forma:

$$Y_{it} = \alpha + \gamma_i + \lambda_t + \tau Treat_i \cdot Post_t + \epsilon_{it}$$

Donde γ_i son *unit fixed effects* y λ_t son *time fixed effects*.

Y la forma canónica:

$$Y_{it} = \alpha + \beta Treat_i + \gamma Post_t + \tau Treat_i \cdot Post_t + \epsilon_{it}$$

Y el coeficiente que nos interesa es τ . Notamos que claramente $Treat_i$ es constante en el tiempo y $Post_t$ es constante entre individuos. Por lo tanto, si corremos la siguiente regresión, con efectos fijos por unidad y tiempo, y con las dummies, veremos que R nos excluye las dummies:

```
# Veamos que sucede cuando agregamos efectos fijos y las variables de tratamiento y tiempo:
reg3 <- lfe::felm(y ~ treat + post + treat_post | unidades + time, data = dd_data)
```

²La idea es análoga para los efectos fijos por tiempo, o por otro tipo de grupo.

```
summary(reg3)
Residuals:
    Min       1Q   Median       3Q      Max
-2.64764 -0.37221  0.00372  0.32630  2.40302

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
treat_post     6.1850     0.5573   11.1 2.29e-16 ***
treatment         NaN          NA      NaN      NaN
post            NaN          NA      NaN      NaN
---

```

Además, observamos que la especificación de TWFE es más eficiente (de menor varianza). A su vez, la R^2 es mayor, por lo que TWFE explica mejor la variabilidad en el outcome de interés, esto porque se controla por un mayor número de características constantes en el tiempo y entre unidades, que tan solo agregando las dummies.

```
# Para nuestros datos es:
dd_data <- dd_data %>% mutate(treat_post = treatment*post)

reg2 <- lfe::felm(y ~ treat_post | unidades + time | 0 | unidades, data = dd)

```

Tabla 3: DiD

	<i>Dependent variable:</i>	
	Canonic	TWFE
	(1)	(2)
DiD Estimate	6.185*** (0.067)	6.185*** (0.066)
Treatment	0.076 (0.075)	
Post	2.123*** (0.051)	
Unit Fixed Effects	No	Yes
Time Fixed Effects	No	Yes
Observations	80	80
R ²	0.571	0.941

Notes: Standard errors are clustered at the unit level.
 * denotes $p < 0.1$, ** denotes $p < 0.05$, and *** denotes $p < 0.01$.